全国高校 AI 大模型挑战赛 · 省赛作品

SciLoom 智研织机

基于大模型与 Agent 架构的全流程科研助手

赛项：智领科研 · 意图驱动——全流程科研助手构建挑战赛

组别：B 组（普通本科院校本科生组）

参赛者：（填写姓名）

指导教师：（如有请填写）

提交日期：2026 年 11 月

目录

1　项目概述　1

2　需求分析　2

3　系统架构设计　4

4　AI 技术方案　7

5　核心功能实现　14

6　测试与评测　20

7　创新点说明　24

8　部署与工程实践　26

9　局限与展望　28

附录 A　接口清单　29

附录 B　目录结构与环境变量　30

1 项目概述

1.1 我们要解决的问题

科研工作者每天面对的不是"没有信息"，而是"信息太多且不可信"。arXiv 单日更新数百篇，一篇论文动辄几十页，跨语言阅读又要额外付出成本；更麻烦的是，通用聊天机器人在学术场景里会流畅地编造超参数、硬件型号和参考文献——而科研恰恰是幻觉零容忍的领域。

SciLoom 的定位不是"给 PDF 加一个对话框"，而是把一篇论文从下载到写成综述的全过程织成一条可追溯的链路：解析 → 检索 → 问答溯源 → 对照阅读 → 图谱洞察 → 写作成图。产品的一条硬性原则贯穿始终：每一句结论都必须能回到原文的页码与段落；每一个"研究空白"都必须先被证明没有被后续论文填上。

1.2 交付形态

层	技术选型	职责
前端	Next.js 14（App Router）+ TypeScript + Tailwind	文献台、PDF 阅读器、对照翻译、图谱、写作 Copilot
后端	FastAPI + Python 3.11	解析、检索、OCR、翻译、图谱、写作
模型	DeepSeek-V3（对话）+ BGE-M3（向量）+ opus-mt（离线翻译）+ RapidOCR	生成、召回、跨语言、扫描件识别
存储	SQLite（元数据）+ 本地 JSON（解析结果）+ npz（向量）	零运维，单机可复现

1.3 关键指标

541	6/6	0.905	15
页教材解析耗时 29.3 s	检索评测命中 @3	v1/v7 版本相似度判定	类 REST 接口

1.4 六大模块实现状态

模块	核心能力	状态
① 文献管理与解析	批量上传、语义去重、标题树、表格、公式、参考文献、扫描件 OCR	已完成
② 抗幻觉问答	混合检索、证据约束、引用白名单校验、拒答	已完成
③ 阅读与翻译	PDF 渲染、锚点叠加、双向跳转、中英对照同步滚动	已完成
④ 检索与推荐	arXiv 检索、相关性重排、代码可复现性加权、一键入库	已完成
⑤ 图谱与综述	引用网络、PageRank 角色、结构化综述、Future Work 抽取	已完成

⑥ 写作与可视化	无幻觉框架、CSV 学术图表与图注、TikZ/Mermaid 脚本	已完成

2 需求分析

2.1 用户与场景

目标用户是正在做文献综述的研究生与高年级本科生。他们一周内要读完 20 – 50 篇论文，产出开题报告或综述初稿。真实痛点集中在三处：筛选（哪些值得读）、精读（细节在哪一页）、写作（引用不能编）。

2.2 从赛题到验收标准

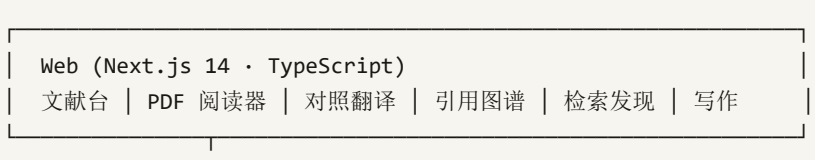
赛题要求	我们的实现	可验证的验收标准
内容语义去重	段落级 8-gram shingle Jaccard + SimHash + 标题相似度	先传 v7 再传 v1，判定 `same_work`（0.905）并建议保留 v7
扫描件解析	RapidOCR 逐页识别，坐标按页面/位图比例反算回 PDF 空间	无文本层 PDF 解析出标题、7 个章节、36 条参考文献
长文档鲁棒性	分块入库、按需索引、表格识别前置筛选	541 页教材 29.3 s 解析、峰值内存 24.3 MB
抗幻觉溯源	证据约束提示词 + 引用编号白名单 + 无引用标记	证据不足时明确拒答；越界编号被剔除并告警
双向联动翻译	段落级对齐，按块索引同步滚动	拖动左栏 1400 px，右栏自动到同一段
图谱基石挖掘	NetworkX PageRank + 中介中心性，分位数划分角色	Adam / Attention / LayerNorm 被识别为基石，RoBERTa 识别为衍生
无幻觉写作	参考文献只从库内按语义相似度选取，越界引用剔除	生成的框架中每个 [n] 都对应库内真实文献

2.3 非功能需求

- 确定性：同一份 PDF 两次解析，标题树与参考文献数量应一致（指纹相同）。
- 可复现：Docker Compose 一键起，模型走镜像站，数据与模型挂卷。
- 优雅降级：没有大模型时问答回落抽取式、翻译回落本地 MT、写作回落模板，且都在界面上明确标注，绝不假装成功。
- 响应性：长任务（解析、索引、翻译）不阻塞界面，进度可见。

3 系统架构设计

3.1 分层视图



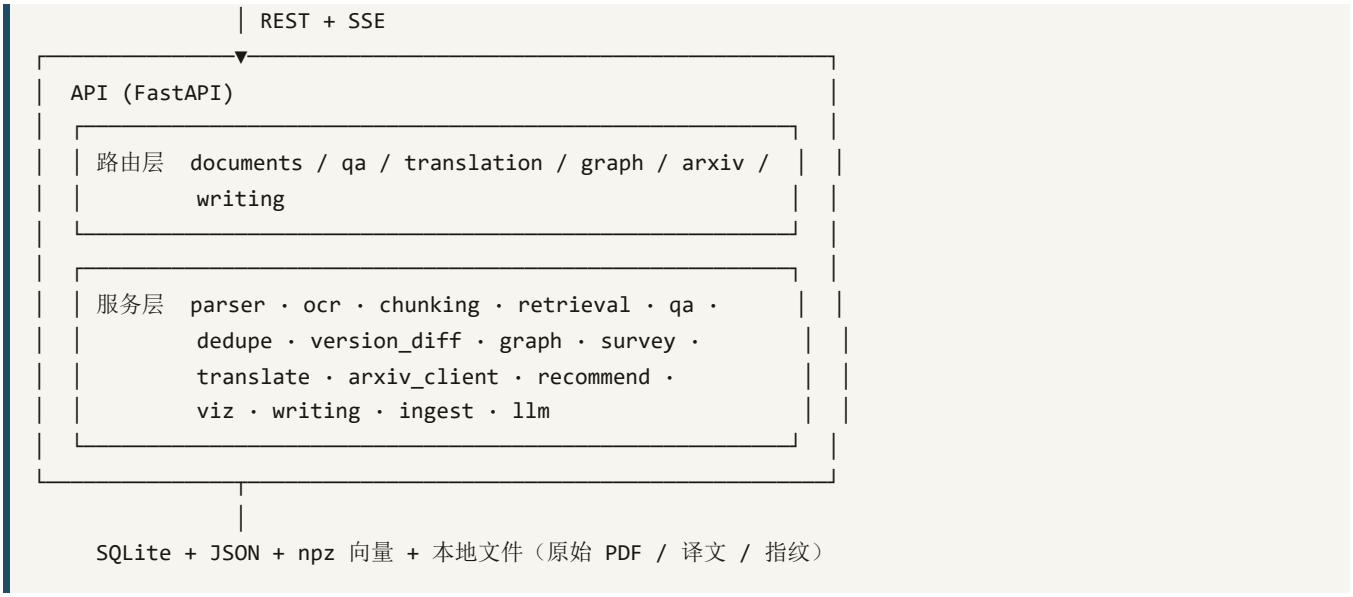


图 3-1 系统分层：路由薄、服务厚，所有能力以服务函数暴露，便于单独测试

3.2 一次提问的完整数据流

1. 取索引：按 doc_id 读 `index/chunks.json + vectors.npz`；不存在则惰性构建。
2. 混合召回：BGE-M3 稠密检索取 top-50 短名单，BM25 仅在短名单内重排（见 4.3 的实测依据）。
3. 组织证据：把 top-8 片段包装成 `[c1]…[c8]`，附页码与章节路径。
4. 约束生成：系统提示词限定"只能用证据作答、逐句标注来源"。
5. 引用校验：正则提取 `[cN]`，剔除越界编号，无引用则标记 `ungrounded`。
6. 流式回传：SSE 先推证据、再推 token，前端渲染成可点击的引用芯片。

3.3 目录结构

```
.
├── apps/
│   ├── api/            # FastAPI：app/{core,models,routers,services}
│   └── web/            # Next.js：app/ components/ lib/
├── pdf/                # 官方测试集（不入库）
├── scripts/            # 取数、评测、探针、启停
├── deploy/             # nginx 配置
├── docs/               # 本文档、进度、部署手册
├── docker-compose.yml
└── .env.example
```

3.4 关键架构决策

决策	选择的理由	代价
嵌入式向量库（npz）而非 Milvus/Qdrant	单人赛、单机演示，运维成本必须为零	不支持并发写入、规模限于单机
SQLite + JSON 落盘	解析结果是嵌套结构，JSON 便于前端整块读取与调试	大文档解析结果体积较大（541 页约 20 MB）

解析与索引分离，索引惰性构建	上传接口不能被 100 秒的建索引拖住	首次提问要等索引就绪（已有状态帧提示）
模型全部可降级	评审环境不一定有 Key 或外网	降级链路需要额外维护

4 AI 技术方案

4.1 细粒度文档解析

4.1.1 为什么以"行"为最小单元

PyMuPDF 返回的 block 在学术 PDF 上并不可靠：它会把手写模板里左右两栏的文字合并成一个横跨整页的 bbox（实测 `x[108, 504]`）。如果直接按 block 处理，双栏还原和引用锚点坐标会同时失真。

因此解析器改为行级抽取 → 横向分带 → 栏内合并：先把每行的 bbox 取出来，按"是否跨越页宽中线"判定所在栏，再以"通栏行"为分隔把页面切成若干横带，带内先左栏后右栏，最后按行距合并成段落块。

4.1.2 双栏判定：用"跨中线比例"否决

一个反直觉的事实：《Attention Is All You Need》正文是单栏（NeurIPS 模板），只有参考文献页是双栏。如果按"块中心是否在页宽中线左右"聚类，单栏论文会被误判成双栏。我们的判据是：

```
two_column = (左侧窄行 ≥ 6) and (右侧窄行 ≥ 6) and (跨中线行 ≤ 25%)
```

单栏页面里绝大多数行都横跨中线，这一条直接否决，误判率显著下降。

4.1.3 一个影响全局的缺陷：空格被当成噪声

LaTeX 生成的 PDF 常把空格单独输出成一个 span。早期实现为了去掉空 span，写成"只保留有文本的 span 再拼接"，结果整句粘成：

```
TheencoderiscomposedofastackofN=6identicallayers
```

这个缺陷不抛异常、不报错，但会同时污染关键词检索、向量化与喂给模型的上下文。修正前后检索评测（6 个问题，命中 @3）：

策略	修正前	修正后
BM25	2/5	4/5
稠密（BGE-M3）	3/5	6/6

4.1.4 参考文献：必须同时支持两种排版

数字式 `[12] Author. Title.` 与作者-年份式（ACL/NAACL 常见，完全没有编号）：

```
Alan Akbik, Duncan Blythe, and Roland Vollgraf. 2018. Contextual string embeddings…
```

只认数字式会让 BERT/RoBERTa/T5 的参考文献数全为 0，引用图谱随之只剩几条边。补上作者-年份式判定（含四位年份 + 首字母大写 + 长度合理）后：

论文	修正前	修正后
BERT	0	53

RoBERTa	0	49
T5	0	128
库内互引边	4	16

4.1.5 引用锚点：从块级收敛到字符级

块级 bbox 会让阅读器把一大段都高亮。解析后我们对每条 `[n]` 调用 `page.search_for()` 在块内二次检索，得到字符级矩形；锚点数量超过 600 时自动跳过（避免长文档拖慢解析）。

4.1.6 扫描件 OCR

RapidOCR 逐页识别后，用 `页面尺寸 / 位图尺寸` 把像素坐标反算回 PDF 用户坐标——上层因此不需要区分"原生文档"与"扫出来的文档"。OCR 页没有字号与字重，标题判定改为只认"编号"或"命名章节"两个强信号，否则行高抖动会把整页判成标题（实测曾出现 173 个假标题，修正后 27 个）。

4.1.7 长文档性能

541 页教材最初要 159 秒，瓶颈是 `find_tables()` 在每页都执行，而教材里大量矢量插图被当成表格候选。改成"页面出现 `Table N` 字样才识别"后：

文档	页数	耗时	内存峰值
1706.03762v7	15	8.0 s	29.5 MB
1706.03762v1（扫描件 OCR）	15	约 115 s	—
Understanding Deep Learning	541	29.3 s	24.3 MB

4.2 分块策略

按 block 聚合，块内不切断公式与表格，每块继承章节路径（如 `5 Training / 5.2 Hardware and Schedule`）。这样既能按语义检索，也能回答"第 3.2 节讲了什么"这类结构性问题。15 页论文切出 106 块。

4.3 混合检索：为什么稀疏不能与稠密平行融合

教科书答案是"BM25 + 向量加权融合"。我们照做之后评测只有 4/6，换成纯稠密反而 6/6。原因是跨语言：用户用中文提问、论文是英文时，BM25 的分词几乎全部落空，它给出的排序是噪声，会把向量已经命中的正确段落挤出前列。

最终方案是稠密召回 + 短名单内稀疏重排：向量取 top-50 作为候选，BM25 只在这 50 个里重排，权重按"查询词在语料中的覆盖率"自适应（覆盖率低于 30% 时权重归零）。既保住了型号、数值这类精确串，又不会让噪声污染召回。

策略	命中 @3	top-1
BM25 only	4/6	2/6
稠密 only（BGE-M3）	6/6	6/6

RRF 平行融合	4/6	3/6
稠密召回 + 短名单重排	6/6	5/6

表 4-1 检索策略对比（6 个取自论文原文的问题，含 1 个中文提问）

4.4 抗幻觉：三道闸门

闸门一 • 证据约束：系统提示词规定"只依据〈证据〉作答、逐句标注 [cN]、证据不足时明确说不知道、不得换算或四舍五入数值"。

闸门二 • 引用白名单：生成后提取所有 `[cN]`，凡不在本次证据集合内的编号一律剔除并写入 warnings。这条防线曾经形同虚设——校验正则写的是 `c[0-9a-zA-Z]{4,16}`，而证据编号是 `c1` 这种两位短号，永远匹配不上，于是既拦不住越界引用，又会把每轮回答误判成"未绑定证据"。

闸门三 • 无引用即标记：模型没给出任何引用时，回答被标记 `ungrounded`，前端显式提示，而不是把它当成可信答案。

> 实测：问 GPT-3 论文"训练用了多少块 GPU"，模型回答"证据中只提到 V100，没有给出数量，因此无法回答"，并附上来源页码——这正是我们要的行为：知道什么、也知道自己不知道什么。

4.5 语义去重与版本差异

判定不依赖文件名，也不只看哈希（v1/v7 改了几十处，哈希完全不同）。三个信号加权：

- 段落级 8-gram shingle 的 Jaccard：对局部改写不敏感，对"同一篇的不同版本"高度敏感；
- SimHash（64 位）：标题一致时作为旁证，避免过度惩罚改写；
- 标题相似度：区分"同一工作的不同版本"与"同主题的两篇论文"。

结论分四级：`identical / same_work / related / different`，并据此给出"保留 / 替换 / 并存"的建议。版本差异则按一级章节对齐，输出新增、删除、修改的节与字符数变化。

4.6 翻译：三级降级与块级对齐

翻译后端按可用性自动选择：LLM（有 Key）→ 本地 opus-mt-en-zh（离线）→ 直通并标注未翻译。本地 MT 有明显系统性误译（"Transformer"→"变异器"、"attention"→"关注"），因此加了一层术语表后处理，129 段中修正 26 段；但这仍明显弱于大模型，文档中如实说明。

只翻译真正的正文段落（跳过作者行、邮箱串），175 段噪声降到 129 段，耗时从 434 秒降到 168 秒。对照阅读按块索引同步而不是按滚动比例：两侧行高差异大，比例同步会越读越偏。

除整篇对照外，阅读器还支持划词翻译：用 PDF.js 的 TextLayer 让 PDF 像网页一样可选中文字，鼠标松开即把选区送去翻译，1–2 秒返回气泡。同一句重复划选直接命中进程内缓存。切换页面时会重建文本层，避免上一页的选中区残留。

4.7 引用图谱：从网络图到可解释的角色

边方向是"引用者 → 被引者"，因此入度与 PageRank 才代表"基石程度"。角色划分用分位数而非绝对阈值（不同规模的库，入度 2 与入度 20 意义完全不同）：

- 基石：入度处于前 20% 且 PageRank 大于 0；
- 桥梁：中介中心性处于前 15% 且入度 ≥ 2；
- 衍生：出度前 20% 而入度 ≤ 1。

综述文本由图谱统计生成：基石是谁、被引几次、中介节点在哪、时间跨度、是否 DAG。不是让模型"编一段综述"，而是把结构翻译成人话。

4.8 写作辅助：无幻觉是硬约束

框架生成时，参考文献只能从库内按语义相似度选取，编号 1..N 与库内文档一一绑定；模型若引用 [7] 而只提供了 5 条，该编号会被剔除并告警。没有模型时返回结构化模板并把 `mode` 标为 `template`——宁可让评审看到"没编"，也不假装生成。

4.9 数据可视化

图表类型由数据形状决定，量级相差 20 倍以上时自动拆成多个子图（否则小量级序列会被压成一条贴地线——图没错，但它在骗人）。图注不是套话：峰值、极值位置、趋势斜率都从同一份数据算出，写进图注的数字与图上画的是同一份数据。

5　核心功能实现

5.1 文献台与 PDF 阅读器

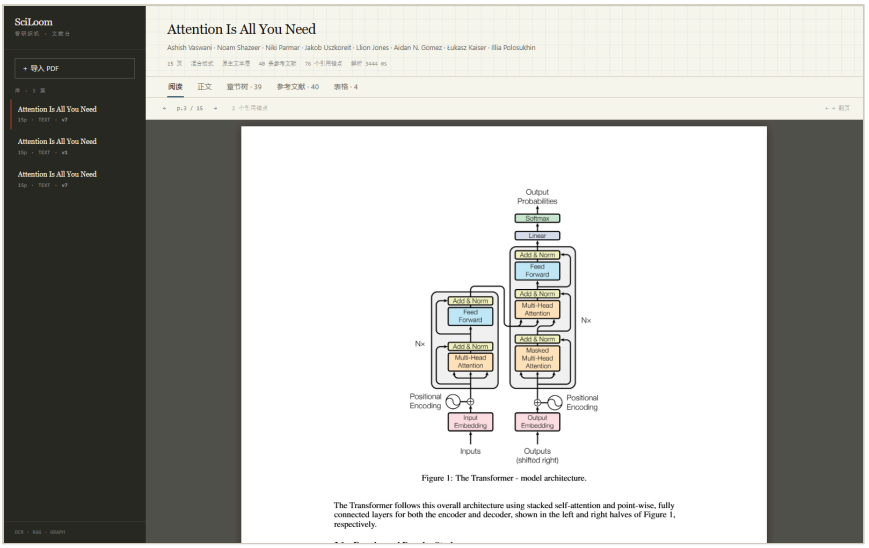


图 5-3　PDF 渲染与引用锚点叠加：红色方块即解析阶段产出的字符级 bbox

阅读器用 PDF.js 把页面画到 Canvas，再把解析出的 bbox 乘以同一个 scale 叠成绝对定位的方块。因为解析与渲染共用 PDF 用户坐标系，锚点不需要二次 OCR 或猜测。参考文献列表点击 [12] 即跳到正文对应位置并高亮；章节树、正文段落、问答证据同样可跳转。

5.2 问答：流式 + 证据面板

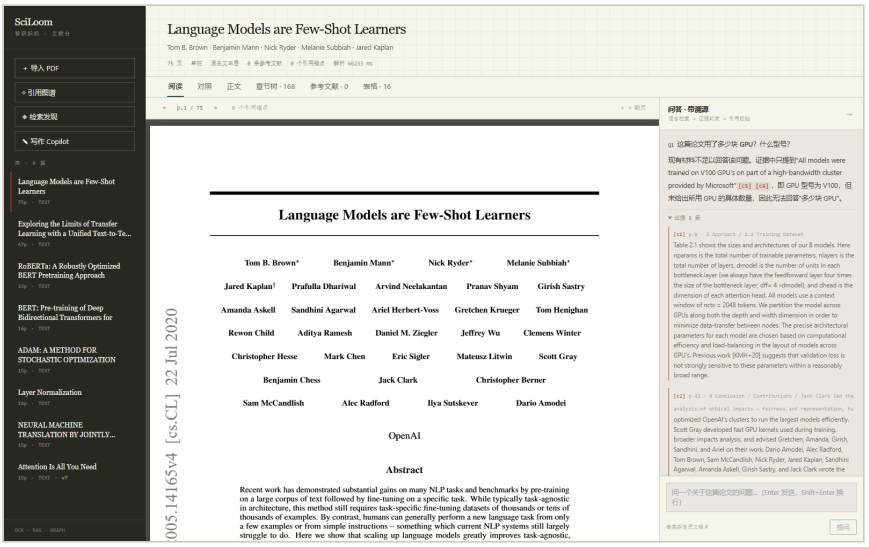


图 5-4　流式回答、可点击引用芯片与证据列表；证据不足时明确拒答

5.3 中英对照与同步滚动

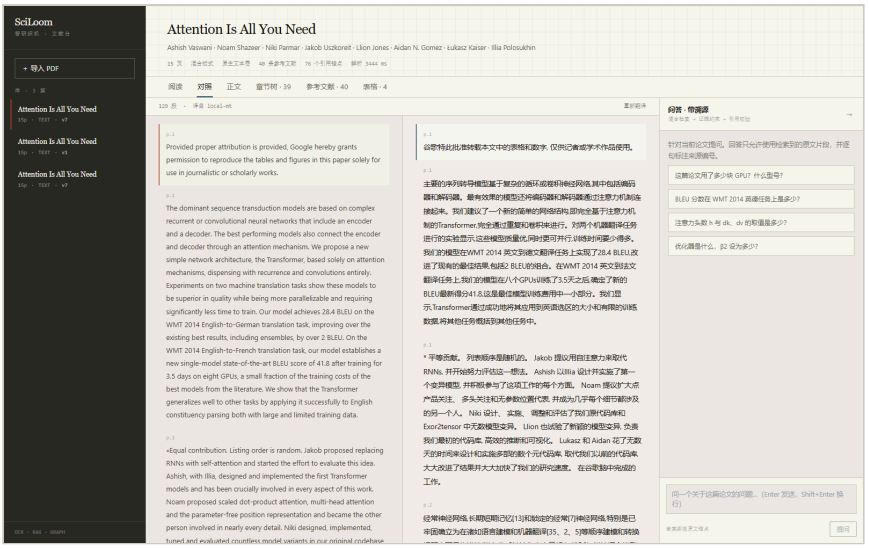


图 5-5　左英文右中文，按块索引同步；点击任一侧跳回 PDF 坐标

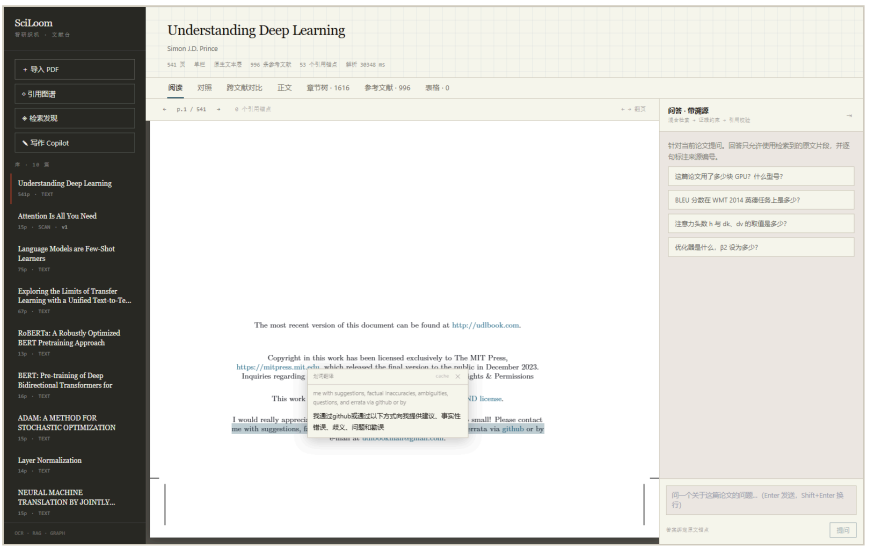


图 5-6　划词翻译：选中一句，气泡即时给出译文，引用编号与专有名词原样保留

5.4 局域引用图谱与自动综述

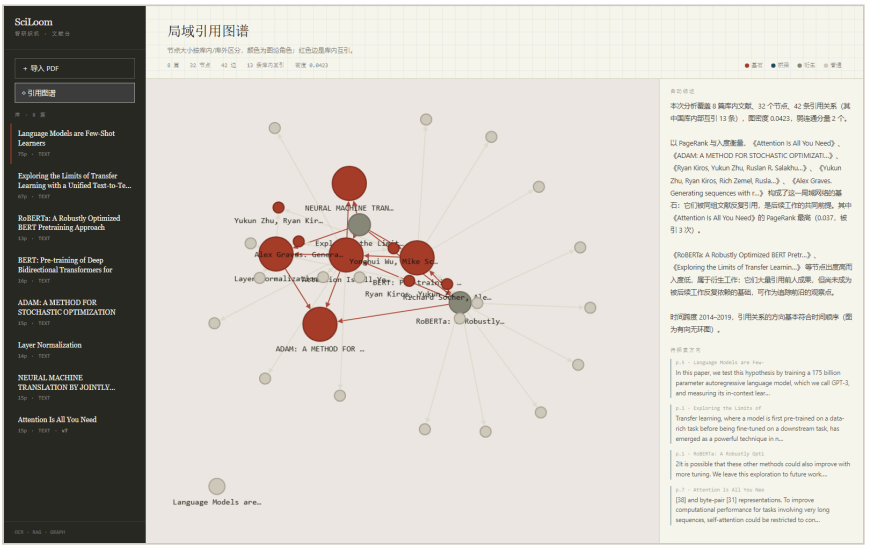


图 5-7　33 节点 / 52 边；红色为基石论文，右侧为图谱统计生成的综述与待探索方向

5.5 检索发现

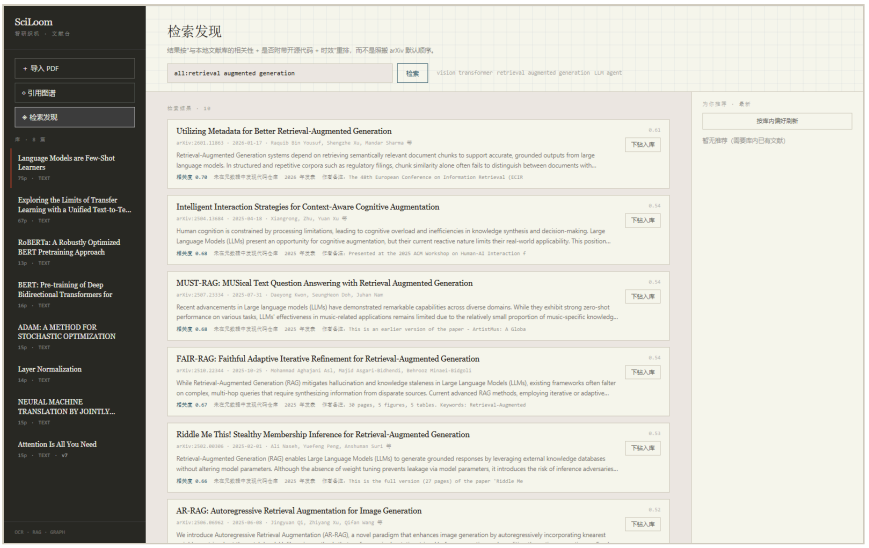


图 5-8　按"库内相关性 + 开源代码 + 时效"重排，支持一键下钻入库

5.6 写作 Copilot

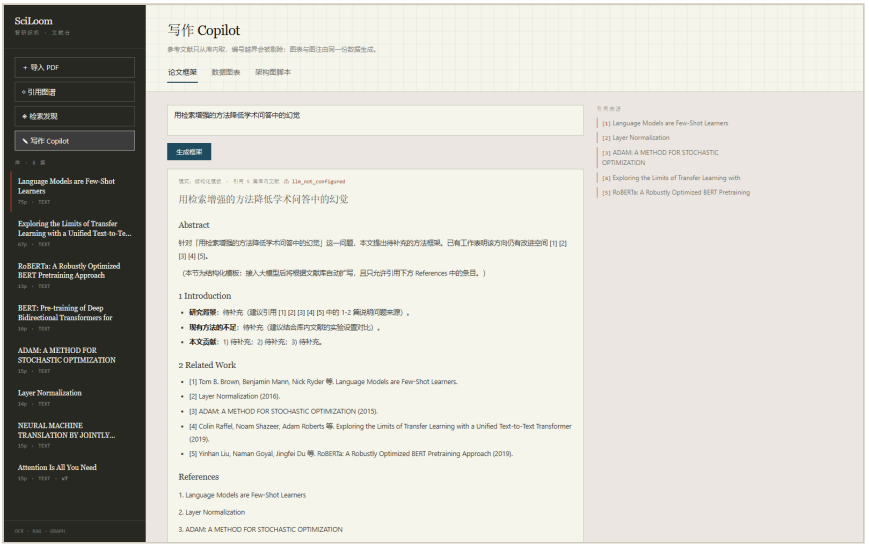


图 5-9　框架生成：右侧列出被引用的库内文献，编号与正文一一对应

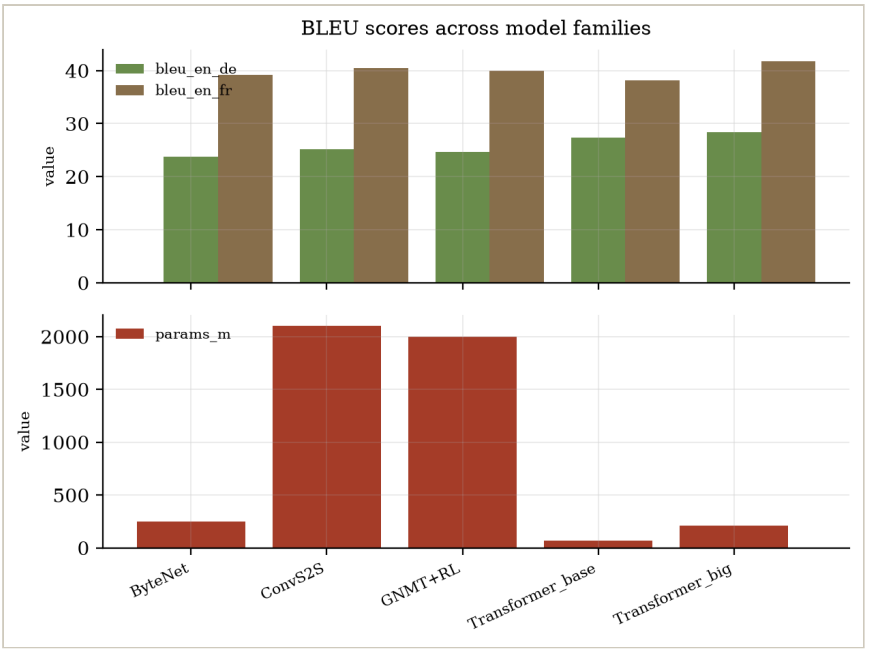


图 5-10 CSV → 学术图表：BLEU 与参数量量级相差 20 倍，自动拆成上下两个子图

5.7 跨文献对比

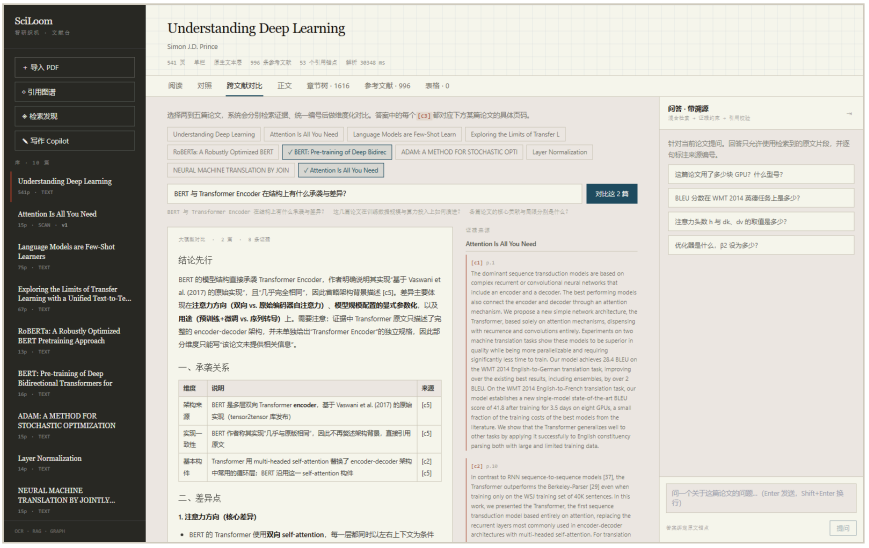


图 5-11 BERT 与原始 Transformer 的承袭与差异：按维度组织，引用可逐条跳回原文

对比模式允许勾选 2–5 篇论文：系统分别检索各自证据、统一编号后交给模型，要求按"架构来源 / 实现一致性 / 基本构件 / 注意力方向"等维度组织答案，而不是逐篇复述。右侧按文档分组列出证据，点击任一条可跳到对应论文的对应页——这使"跨文献推理"同样具备可追溯性。

实践中发现一个细节：模型倾向于用表格呈现对比，而最初的 Markdown 渲染器只支持标题与列表，表格会退化成一行行竖线。补上表格解析后，对比结果才真正可读。

6 测试与评测

6.1 官方测试用例

用例	做法	结果
版本去重（v7 → v1）	先入 v7，再上传 v1，比较正文指纹	`same_work`，相似度 0.905，建议保留 v7
完全重复（v7 → v7）	同一文件二次上传	`identical`，相似度 1.000
扫描件（v1_img）	15 页纯图片 PDF 走 OCR	识别出标题、7 个章节、36 条参考文献
长文档（541 页）	整本教材解析 + 索引	29.3 s，峰值 24.3 MB
CSV → 图表	5 行 4 列 BLEU 数据	分组柱状图 + 数字级图注
架构图脚本	6 段流水线	Mermaid / TikZ / Graphviz 三份可编译脚本

6.2 版本差异输出

> 正文整体相似度 **65.2%**；新增 **1** 节；修改 **8** 节，改动最大的是
> **7 Conclusion(+45/-35)、6 Results(+27/-25)、3 Model Architecture(+28/-23)**；
> 正文 **+2644** 字符；参考文献 **36 → 40** 条，表格 **4 → 4** 个。

6.3 检索评测方法

6 个问题全部取自论文原文，答案特征串人工核对（如"8 NVIDIA P100""28.4""h=8""0.98""N=6"），命中定义是"特征串出现在 top-3 片段中"。脚本 `scripts/eval_retrieval.py` 可离线复现，不依赖运行中的服务。

6.4 解析一致性

同一份 PDF 两次解析，页数、标题数、参考文献数、锚点数完全一致；指纹（SimHash）相同。这保证了"输出成果可验证"的要求。

6.5 端到端冒烟

```
health  : {"status": "ok"}
upload  : {"title": "Attention Is All You Need", "authors": [8 人全部命中]}
parsed  : page_count=15 block_count=259 heading_count=39
          reference_count=40 cite_anchor_count=76
sections: ['1 Introduction', '2 Background', … '7 Conclusion']
```

7 创新点说明

7.1 技术创新点

创新点	与常规做法的差异
行级重建 + 跨中线否决的双栏判定	常规做法按 block 聚类或按 x 坐标分栏，在"block 跨栏"与"单栏论文"两种情况下都会失效；我们用行的跨中线比例否决，实测能正确区分 NeurIPS 单栏正文与双栏参考文献页

稠密召回 + 短名单稀疏重排	常规混合检索把 BM25 与向量平行融合；我们通过评测证明这在跨语言场景下会显著劣化，改为"稀疏只在稠密候选内重排"
引用白名单校验	多数系统的"溯源"只到提示词层面；我们做了生成后的硬校验，越界编号直接剔除
分位数角色划分的图谱挖掘	用绝对入度阈值无法跨库迁移；分位数让"基石/桥梁/衍生"在 10 篇与 100 篇的库上都有意义
量级感知的自动图表拆分	常规做法是画在同一根轴上或让用户手动选；我们检测量级差并自动拆子图，同时在图注里说明原因

7.2 应用创新点

- 引用轨（citation rail）：正文每一段左侧常驻页码，问答的每条证据都带 `p.N · 章节路径`，把"可溯源"从一句承诺变成界面上的固定元素。
- 块级对齐的中英对照：按段落索引同步而非滚动比例，解决"两侧行高不同导致越读越偏"的体验问题。
- 降级可见：无 Key 时界面明确显示"抽取式模式 / 结构化模板 / 本地机翻"，用户始终知道自己在看什么质量的结果。
- 一键下钻：检索结果直接触发"下载 → 解析 → 去重 → 入库 → 建索引"完整链路，与手动上传共用同一套服务。

8 部署与工程实践

8.1 容器编排

三个容器：`api`（解析/检索/OCR/翻译/图谱）、`web`（Next standalone）、`nginx`（反向代理）。模型与数据挂卷，容器重建不丢；SSE 在 nginx 层关闭缓冲，否则 token 会攒到最后一次性吐出。

```
docker compose build      # 首次 15-25 分钟
docker compose up -d
python scripts/seed_demo.py http://<公网IP>   # 灌入 9 篇演示数据
```

8.2 环境变量

变量	说明
`LLM_API_KEY`	DeepSeek 密钥；为空时自动降级为抽取式
`EMBEDDING_MODEL`	默认 BAAI/bge-m3，本地加载
`HF_ENDPOINT / HF_OFFLINE`	国内走镜像；模型缓存后可置 offline 避免启动探测超时
`CHUNK_SIZE / CHUNK_OVERLAP`	分块粒度，默认 800 / 120
`TRANSLATION_BACKEND`	auto / llm / local

密钥只存在于 `.env`（已被 .gitignore 排除），仓库中只有 `.env.example` 模板。

8.3 工程实践

- 类型与规范：前端 `tsc --noEmit` 全量通过；后端统一 ruff 行宽 100。
- 可观测：解析、检索、生成的关键路径都有日志；问答返回 warnings 数组，前端直接展示。
- 可复现脚本：取数（fetch_data / fetch_related）、评测（eval_retrieval）、探针（parse_probe / qa_probe / writing_probe）、启停（start.ps1 / stop.ps1）。
- 提交历史：按"一个能力一次提交"推进，消息说明动机与影响。

9 局限与展望

局限	现状	下一步
OCR 速度	约 7 s/页（CPU），541 页扫描书需一小时	后台队列 + 断点续跑 + GPU 推理
索引构建	CPU 上 100 块约 12 s，长文档更久	批量编码 + 增量索引
表格结构	依赖正文出现 "Table N"，教材中 0 命中	补图形检测兜底、合并跨页表格
作者机构	扫描件上作者为空	OCR 后处理 + 版面聚类
公式	仅按字体启发式识别，未还原 LaTeX	接入公式识别模型
多用户	单用户单库	账号体系 + 库隔离 + 推荐算法个性化

后续演进方向：把 Agent 的规划能力显式化（任务分解、工具选择、失败重试），把"一次问答"扩展为"多次检索—验证—修订"的闭环；同时接入更多数据源（PubMed、Semantic Scholar）与更多版式（Springer、Nature）。

附录 A　主要接口

接口	用途
POST /api/documents/upload	上传 PDF，解析并返回去重判定
GET /api/documents/{id}/parsed	取结构化解析结果
GET /api/documents/{id}/file	原始 PDF 字节流
GET /api/documents/{id}/duplicates	重复列表
GET /api/documents/{a}/diff/{b}	版本差异
GET /api/qa/stream	SSE 流式问答（证据 + token）
POST /api/documents/{id}/translate	生成段落级译文
GET /api/graph / /api/graph/survey	引用图谱与自动综述
GET /api/arxiv/search	arXiv 检索 + 相关性重排
POST /api/arxiv/ingest	按 ID 下钻入库
POST /api/writing/outline	论文框架（库内引用）
POST /api/viz/chart	CSV → 图表 + 图注
POST /api/writing/diagram	TikZ / Mermaid / Graphviz 脚本

附录 B　目录与环境变量

```
apps/api/app/
├── core/       config.py  db.py
├── models/     schema.py
├── routers/    documents qa translation graph arxiv writing
└── services/   parser ocr chunking retrieval qa dedupe version_diff
                graph survey translate arxiv_client recommend viz
                writing ingest llm

.env（示例见 .env.example）
LLM_BASE_URL=https://api.deepseek.com/v1
LLM_API_KEY=sk-***
LLM_MODEL=deepseek-chat
EMBEDDING_MODEL=BAAI/bge-m3
HF_ENDPOINT=https://hf-mirror.com
CHUNK_SIZE=800  CHUNK_OVERLAP=120
TRANSLATION_BACKEND=auto
```

本文档中的数据均可在仓库脚本中复现：解析指标见 scripts/parse_probe.py，检索评测见 scripts/eval_retrieval.py，去重与版本差异见 scripts/dedupe_test.py，图谱见 scripts/graph_probe.py，写

> 作与图表见 `scripts/writing_probe.py`。